

BABEŞ–BOLYAI UNIVERSITY OF CLUJ-NAPOCA
FACULTY OF MATHEMATICS AND INFORMATICS
SPECIALIZATION: COMPUTER SCIENCE

Diploma Thesis

Classification of Elliptical and Spiral Galaxies using Convolutional Neural Networks



ADVISOR:

ÁGNES MESTER, PHD.
ASSISTANT LECTURER

STUDENT:

BALÁS BOTOND BARNA

2023

UNIVERSITATEA BABEŞ–BOLYAI, CLUJ-NAPOCA
FACULTATEA DE MATEMATICĂ ȘI INFORMATICĂ
SPECIALIZAREA INFORMATICĂ

Lucrare de licență

**Clasificarea galaxiilor eliptice și spiralate
folosind Rețele Neuronale Convoluționale**



CONDUCĂTOR ȘTIINȚIFIC:

ASISTENT UNIVERSITAR
DR. ÁGNES MESTER

ABSOLVENT:

BALÁS BOTOND BARNA

2023

BABEŞ–BOLYAI TUDOMÁNYEGYETEM KOLOZSVÁR
MATEMATIKA ÉS INFORMATIKA KAR
INFORMATIKA SZAK

Szakdolgozat

**Elliptikus és Spirálgalaxisok Osztályozása
Konvolúciós Neurális Hálózatok
Segítségével**



TÉMAVEZETŐ:

DR. MESTER ÁGNES,
TANÁRSEGÉD

SZERZŐ:

BALÁS BOTOND BARNA

2023

BABEŞ–BOLYAI UNIVERSITY OF CLUJ-NAPOCA
FACULTY OF MATHEMATICS AND INFORMATICS
SPECIALIZATION: COMPUTER SCIENCE

Diploma Thesis

Classification of Elliptical and Spiral Galaxies using Convolutional Neural Networks

Abstract

This paper presents a few convolutional neural networks for galaxy classification. A galaxy can be labeled as elliptical, spiral or irregular, according to Edwin Hubble's galaxy morphological classification. The four presented neural networks solve a binary classification task, specifically, they classify the galaxies into elliptical and spiral classes; the first NN uses Deep Galaxy V2's architecture, the second and third networks are more complex variations of the latter, while the fourth is a ResNet-18 network. The networks were trained over 120432 images and tested over 13380 images. Furthermore, they were manually tested with a few images which were made using the JWST's data. These images and their corresponding classifications are studied in the paper pointing out the potential of the networks' of classifying galaxies coming from new equipment's data by training the models with data collected by older equipments.

This work is the result of my own activity. I have neither given nor received unauthorized assistance on this work.

2023

BALÁS BOTOND BARNA

ADVISOR:
ÁGNES MESTER, PHD.
ASSISTANT LECTURER

Tartalomjegyzék

1. Bevezető		3
1.1. Motiváció	3	
1.2. Galaxisok	3	
1.3. STScI, MAST & Hello Universe	3	
1.4. James Webb Space Telescope	4	
1.5. A dolgozat célja	4	
2. Neurális hálózatok		5
2.1. A Neurális hálózatok felépítése	5	
2.2. Konvolúciós Neurális Hálózatok	5	
2.3. ResNet	7	
3. Felhasznált adatok		9
3.1. Galaxy Zoo (Zooniverse)	9	
3.2. Felhasznált adatok		9
3.2.1. Tanítás és validálás	9	
3.2.2. Tesztelés	9	
3.2.3. JWST Adatok	10	
4. Kipróbált Architektúrák		14
4.1. Deep Galaxy V2	14	
4.1.1. Az architektúra	14	
4.1.2. Eredmények	14	
4.2. Saját módosítások	14	
4.2.1. Az architektúrák	14	
4.2.2. Eredmények	15	
4.3. ResNet-18	16	
4.3.1. Az architektúra	16	
4.3.2. Eredmények	16	
4.4. Összehasonlítás	16	
5. JWST Eredmények		23
6. Felhasznált technológiák		28
6.1. Python & Jupyter notebook	28	
6.1.1. Használt függőségek	28	
6.2. MAST Portál	28	
6.3. Preview	28	
7. Konklúzió és továbbfejlesztés		29
7.1. Konklúzió	29	
7.2. Továbbfejlesztési lehetőségek	29	
A. Felhasznált adatok példája		30

1. fejezet

Bevezető

1.1. Motiváció

A gépi tanulás alkalmazása napjainkban szinte elengethetetlenné vált a csillagászat területén. A megfigyeléses csillagászat hatalmas mennyiségű adatot generál, amelyet manuálisan lehetetlen lenne hatékonyan feldolgozni és elemezni. A gépi tanulási módszerek lehetővé teszik a bejövő adatok automatizált feldolgozását és a gyors információkinyerést, és eredményesen alkalmazhatók különböző objektumok osztályozására és azonosítására, ritka jelenségek és anomáliák megkülönböztetésére, vagy az adatokban rejlő összefüggések és minták felfedezésére.

1.2. Galaxisok

A galaxisokat először Edwin Hubble osztályozta elliptikus és spirális kategóriákba¹. Ezen osztályok jellemzően más tulajdonsággal rendelkeznek [Graham, 2019], például az elliptikus galaxisok jellemzően öregebbek, mint a spirális galaxisok²[Abraham és van den Bergh, 2001]. A galaxisok formálódása a gravitációs hatások miatt a sötét anyag kutatásában is jelentőséggel bír [Romanowsky et al., 2003], ezért indokolt a galaxisok osztályozásának automatizálása.

1.3. STScI, MAST & Hello Universe

A Space Telescope Science Institute (STScI) egyetemek azon egyesülete, melynek célja kutatás a csillagászatban³. 1981-es fennállása óta több neves űrteleszkóp kezelésében segítkeztek, mint például a Hubble vagy James Webb űrteleszkópok kezelésében. Az űrteleszkópok kezelésén kívül a STScI tartja karban a Mikulski Archívumot is (Mikulski Archive for Space Telescopes; MAST), melynek célja elérhetővé tenni a csillagászati adatokat⁴. Ezen archívum

¹<https://esahubble.org/images/heic9902o/>

²<https://universe.nasa.gov/galaxies/types/>

³<https://www.stsci.edu/who-we-are>

⁴<https://archive.stsci.edu/>

1. FEJEZET: BEVEZETŐ

portálján keresztül⁵ lehetőségünk van letölteni különböző missziók adatait. A teszteléshez felhasznált adatok is ezen portálról származnak.

A MAST továbbá létrehozta a "Hello Universe" projektet is annak érdekében, hogy könnyebb legyen gépi tanulási módszereteket felhasználó programokat fejleszteni, mivel a teleszkópek által generált adatok feldolgozásához elengedhetetlen lesz a gépi tanulás⁶.

1.4. James Webb Space Telescope

A James Webb űrteleszkópot (továbbiakban: JWST) 2021 Decemberében indították útjára olyan célokkal, mint hogy a 13.5 millió éve keletkezett csillagokat és galaxisokat vizsgálja⁷. Első képei 2022 július 12-én lettek kiadva⁸, és az azóta begyűjtött adatmennyiség mérete egyre csak nő. A MAST portálján több mint 230 000 rekordot találunk a JWST misszióra szűrve, amiből több mint 100 000 publikusan elérhető.

1.5. A dolgozat célja

Dolgozatom a JWST adataiból generált képeket osztályozza nem-JWST adatok által tanított gépi tanulási módszerek segítségével. Ez által lehetőségünk van látni, hogy régebbi adatokat milyen mértékben tudunk felhasználni új adatok feldolgozására.

⁵<https://mast.stsci.edu/portal/Mashup/Clients/Mast/Portal.html>

⁶<https://archive.stsci.edu/hello-universe>

⁷https://www.nasa.gov/mission_pages/webb/science/index.html

⁸<https://webb.nasa.gov/content/webbLaunch/needToKnow.html#featured>

2. fejezet

Neurális hálózatok

Összefoglaló: Ebben a fejezetben a felhasznált mesterséges neurális hálók technológiáit mutatjuk be a különböző rétegekken keresztül a "shortcut connection"-ökig.

2.1. A Neurális hálózatok felépítése

A mesterséges neurális hálózatok a természetes neurális hálózatokból inspirálódva a neuro-nokat veszik alapmodellnek, és ebből próbálnak komplex hálózatokat létrehozni úgy, hogy ezek minél kisebb hibával visszaadják a várt eredményt.

A legegyszerűbb neurális hálózatok egyike a perceptron. A perceptron a bemeneteinek és a hozzájuk tartozó súlyoknak a szorzatát összegzi, majd ehhez hozzáad egy eltolás értéket és ezt hasonlítja 0-hoz. Amennyiben ez több mint nulla, a kimenete a perceptronnak 1; különben 0. Azaz az aktivációs függvénye:

$$f(x) = \begin{cases} 0, & \text{ha } x \leq 0, \\ 1, & \text{ha } x > 0. \end{cases}$$

Tehát a perceptron esetén az aktivációs függvényt az $x = \mathbf{w} \cdot \mathbf{x} + b$ összegre alkalmazzuk, ahol \mathbf{x} a bemeneti adat vektora, \mathbf{w} a súlyvektor, és b az eltolás értéke.

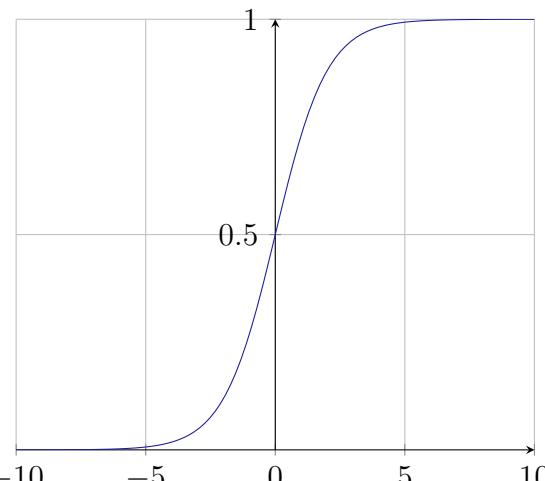
Ennél valamivel komplexebb a többrétegű perceptron (angolul multilayer perceptron, röviden MLP), mely rétegekbe struktúrálva használja fel a perceptronok fogalmát. Itt már az aktivációs függvény szerepét is gyakran más függvény, például a sigmoid függvény (lásd: 2.1 ábra) veszi át az egységugrás függvény¹ helyett [Noriega, 2005], így nem vesz el annyi információ a perceptronok között.

2.2. Konvolúciós Neurális Hálózatok

A Konvolúciós Neurális Hálózatok (angolul convolutional neural network, továbbiakban: CNN) olyan neurális hálózatok, melyek elsősorban képeket dolgoznak fel. Főként konvolúciós rétegekből, pooling rétegekből és teljesen kapcsolt rétegekből állnak.

¹<https://mathworld.wolfram.com/HeavisideStepFunction.html>

2. FEJEZET: NEURÁLIS HÁLÓZATOK



2.1. ábra. A Sigmoid függvény: $f(x) = \frac{1}{1 + e^{-x}}$

Teljesen kapcsolt réteg

A teljesen kapcsolt réteg a többrétegű perceptronoktól ismert réteg, ahol minden neuronnak van kapcsolata az előző réteg összes neuronjával. Ezen neuronok aktivációs függvénye lehet a sigmoid függvény, ReLU (lásd (2.1) függvény), vagy más aktivációs függvény, mint a döntéshozatal esetén a Softmax².

$$f(x) = \begin{cases} 0, & \text{ha } x < 0, \\ x, & \text{ha } x \geq 0. \end{cases} \quad (2.1)$$

Konvolúciós réteg

A konvolúciós rétegek a képeken tárolt tulajdonságokat ismerik fel. Ezekben a rétegekben egy konvolúciós művelet hajtódik végre a kép részein a rétegen tárolt szűrőkkel. Ezen szűrők "csúsztatásával" a szűrő és a kép részei közötti skaláris szorzat adódik tovább.³ ⁴

Pooling réteg

A Pooling réteg lecsökkenti a tensor méreteit és a hálózat paramétereit, ezzel felgyorsítja a tanítását; illetve az overfitting problémában is segít⁵.⁶

²<https://www.engati.com/glossary/softmax-function>

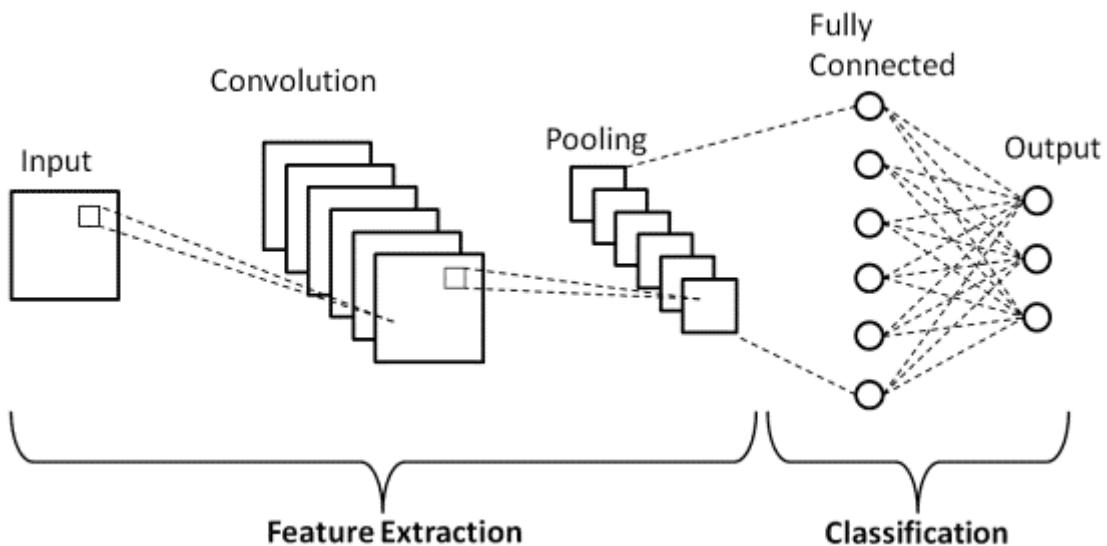
³https://www.upgrad.com/blog/basic-cnn-architecture/#1_Convolutional_Layer

⁴<https://www.youtube.com/watch?v=KuXjwB4LzSA>

⁵Az overfitting-et lehetne "magolás"-ként fordítani, mikor a tanítási adatokra jól teljesít, de a teszt adatokra nem.

⁶<https://cs231n.github.io/convolutional-networks/#pooling-layer>

2. FEJEZET: NEURÁLIS HÁLÓZATOK



2.2. ábra. A Konvolúciós Hálózatok általános felépítése. Forrás: https://www.upgrad.com/blog/basic-cnn-architecture/#Basic_Architecture

A MaxPool két konfigurációban volt használva: 2x2-es illetve 3x3-as szűrővel, minden esetben 2 stride-val.

Ezek a rétegek a konvolúciós réteghez hasonlóan a szűrőt "csúsztatva" vizsgálják a bemenetüket, azonban itt a konvolúció helyett a bemeneti rész maximumát adják tovább. A 2.3-es ábra szemlélteti ahogyan egy 2x2-es szűrő kiválasztja a maximumértékeket. A stride felelős a szűrő elcsúsztatásának mértékével.

DropOut

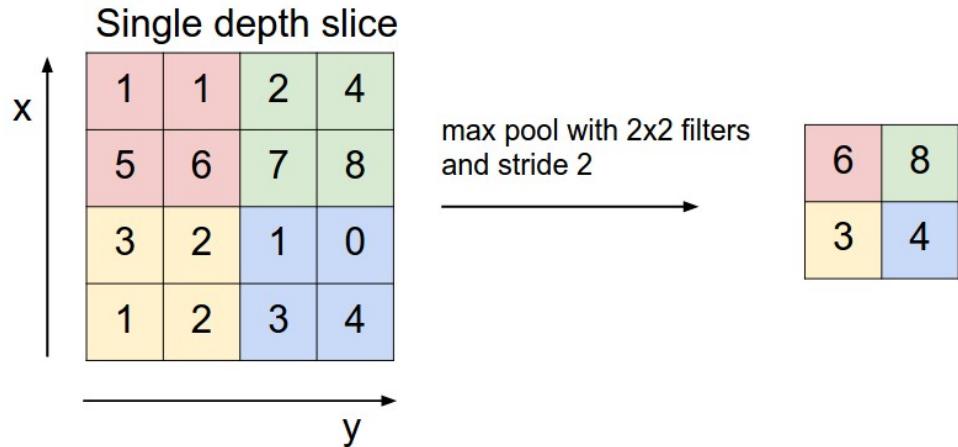
A DropOut réteg ugyancsak az overfitting problémát oldja meg. Ez akkor jelenik meg, mikor a hálózat túlságosan illeszkedik a tanítási adatokra és a tesztadatokon végzett kísérleteken már nem teljesít olyan jól. Az emberi tanulás esetében talán a magolással lehetne párhuzamba vonni. Ezt úgy oldja meg, hogy bizonyos töredékét a neuronoknak véletlenszerűen eldobja a tanítási folyamatban, ezzel is lecsökkentve a hálózat méreteit.⁷

2.3. ResNet

A Residual Network-ok (továbbiakban: ResNet) a konvolúciós hálózatok olyan módosításai, melyek rövidítéseket ("shortcut connection"-okat) vezetnek be. Bizonyos blokkok (residual blokkok) bemenetét a blokk kimenetével kötik össze, ezzel megelőzve az eltűnő/felrobbanó

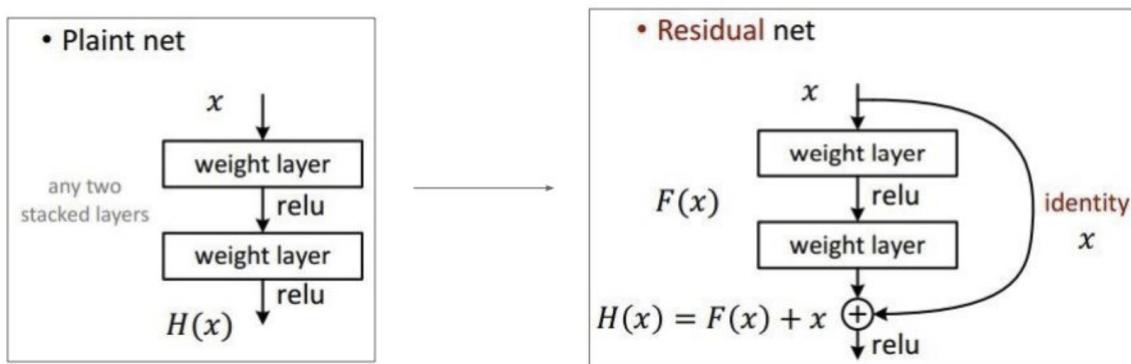
⁷https://www.upgrad.com/blog/basic-cnn-architecture/#4_Dropout

2. FEJEZET: NEURÁLIS HÁLÓZATOK



2.3. ábra. A MaxPool réteg amint a 2x2-es négyzetekből kiválasztja a maximum értékeket. Forrás: <https://cs231n.github.io/convolutional-networks/#pooling-layer>

gradiensek problémáját. A rétegek komplexitásában eltűnhetnek vagy felerősödhetnek a hálózat elején a súlyok befolyásai. Ezt előzi meg ez a technika, mivel a gradienseknek van direkt útjuk vissza a legelső rétegig (Lásd: 2.4). Ezzel lehetővé teszik, hogy a hálózat könnyebben legyen tanítható és a mélységet növelve nagyobb legyen a pontossága[He et al., 2016].



2.4. ábra. A [He et al., 2016]-ben leírt blokk. Forrás: <http://home.mit.bme.hu/~engedy/NN/NN-DL-intro.pdf>

3. fejezet

Felhasznált adatok

Összefoglaló: Ez a fejezet a tanításhoz, validáláshoz és teszteléshez felhasznált adatokat, illetve a JWST adatait tárgyalja.

3.1. Galaxy Zoo (Zooniverse)

A Galaxy Zoo (továbbiakban: GZ) néven indult (mostmár Zooniverse) platform nyílt hozzáférést biztosít megfigyelések által begyűjtött csillagászati adatokhoz, ezáltal lehetőséget nyújtva önkénteseknek az adatok feldolgozására, osztályozására vagy klaszterezésére. A platform indulásakor galaxisok osztályozására adott lehetőséget [Lintott et al., 2010], majd tovább bővítette ezt a projektet [Willett et al., 2013]. Az adatai publikusan elérhetőek¹.

3.2. Felhasznált adatok

A neurális háló tanításához, validálásához és teszteléséhez felhasznált adat a fent említett platform segítségével lett felcímkézve. A felhasznált adat ezen adatok egy részhalmaza². (Példák láthatók az A.1 függelékben).

3.2.1. Tanítás és validálás

A modellek tanításához összesen 120432 képet használtam fel, aminek 4/5-e tanításra és 1/5-e validálásra volt felhasználva; A 120432-ből 81547 elliptikus és 38885 spirális (lásd és 3.1 ábra).

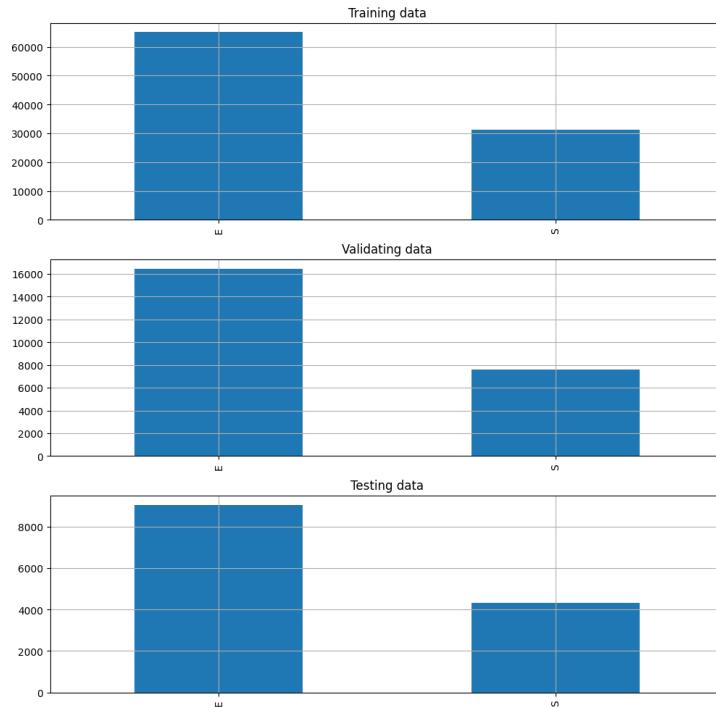
3.2.2. Tesztelés

A modellek teszteléséhez összesen 13380 képet használtam fel, amiből 9060 elliptikus és 4320 spirális (lásd 3.1 ábra).

¹<https://data.galaxyzoo.org/>

²<https://www.kaggle.com/datasets/robertmifsud/resized-reduced-gz2-images>

3. FEJEZET: FELHASZNÁLT ADATOK



3.1. ábra. A képen a tanítási, validálási és tesztelési adatok felosztását láthatjuk. E az elliptikus, míg S a spirálgalaxisokhoz tartozó képeket jelöli.

3.2.3. JWST Adatok

A Galaxy Zoo (mostmár a Zooniverse-en belül) kiegészült egy úgy adathalmazzal a JWST adataiból. Ezen adatok a Cosmic Evolution Early Research Science (továbbiakban CEERS) felmérésből, a Hawaii Two-0 (H20) felmérésből (ami része a Cosmic Dawn felmérésnek) és a DECaLS (Dark Energy Camera Legacy Survey) felmérésből származnak³. 12 képet a CEERS felmérés adataiból vágtam ki, majd a hálózatoknak adtam, hogy prediktálják a képeken látható galaxisok típusát. Karen Masters, a Haverford kollégium professzora és a Zooniverse csapat tagja⁴ emailben elárulta, hogy a GalaxyZoo-n levő képeket is a CEERS publikus TIFF képeiből vágták ki.

Mivel ezek a galaxisok nincsenek még felcímkezve, nem tudtam tesztelni a modelleket ezen nagy mennyiségben.

Képek összeállítása

Mivel a CEERS által kiadott képek a MIRI és a NIRCam eszközök adatait is feldolgozzák, a képek színösszetétele más a két eszköz esetén.⁵

³<https://www.zooniverse.org/projects/zookeeper/galaxy-zoo/about/research>

⁴<https://blog.galaxyzoo.org/2023/06/06/take-a-peek-at-some-jwst-images/>

⁵<https://ceers.github.io/ceers-first-images-release.html>

3. FEJEZET: FELHASZNÁLT ADATOK

A MIRI esetén az F770W, F1000W, F1280W, F1500W, F1800W és F2100W szűrők voltak használva:

- a F770W-es szűrővel készített adatok sötétkék színnel,
- a F1000W-es szűrővel készített adatok világoskék színnel,
- a F1280W-es szűrővel készített adatok türkiz színnel,
- a F1500W-es szűrővel készített adatok zöld színnel,
- a F1800W-es szűrővel készített adatok narancssárga színnel,
- a F2100W-es szűrővel készített adatok piros színnel lettek reprezentálva.

A NIRCam esetén az F115W, F150W, F200W, F277W, F356W és F444W szűrők voltak használva:

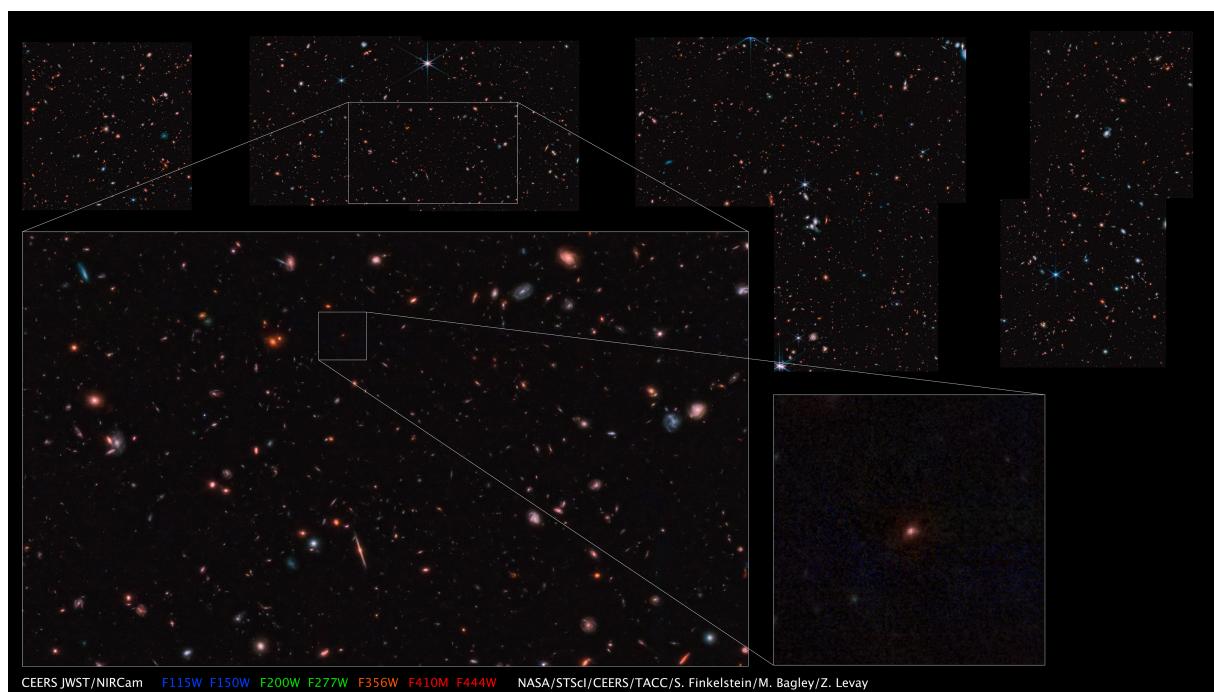
- a F115W-es és a F150W-es szűrővel készített adatok kék színnel,
- a F200W-es és a F277W-es szűrővel készített adatok zöld színnel,
- a F356W-es és a F444W-es szűrővel készített adatok pedig piros színnel lettek reprezentálva.

3. FEJEZET: FELHASZNÁLT ADATOK



3.2. ábra. A képen a CEERS által összeszerkesztett kép található a MIRI adataiból. Az alján látható hogy mely szűrőkkel mért adatokat milyen színnel reprezentálták.

3. FEJEZET: FELHASZNÁLT ADATOK



3.3. ábra. A képen a CEERS által összeszerkesztett kép található a NIRCam adataiból. Az alján látható hogy mely szűrőkkel mért adatokat milyen színnel reprezentálták.

4. fejezet

Kipróbált Architektúrák

Összefoglaló: Az alábbiakban bemutatjuk a Deep Galaxy 2 architektúráját, az azon általunk végzett módosításokat és a ResNet-18 architektúráját. Emellett ismertetjük a GalaxyZoo adatokon végzett tanítás eredményeit is.

4.1. Deep Galaxy V2

4.1.1. Az architektúra

Elsőként a Deep Galaxy V2 [Khalifa et al., 2018] által szemléltetett architektúrából indulunk ki. A bemeneti réteg után a feature extraction-ért egy $[5 \times 5]$ méretű 96 szűrős konvolúciós réteg, egy ReLU aktivációs réteg, egy normalizáló réteg és egy $[3 \times 3]$ -as max-pooling réteg felelős. Ezeket követi egy 24 neuront tartalmazó teljesen kapcsolt réteg, egy ReLU aktivációs réteg, és végül egy két neuront tartalmazó teljesen kapcsolt réteg softmax aktiválással, az osztályozás végett (lásd 4.1-es ábra).

4.1.2. Eredmények

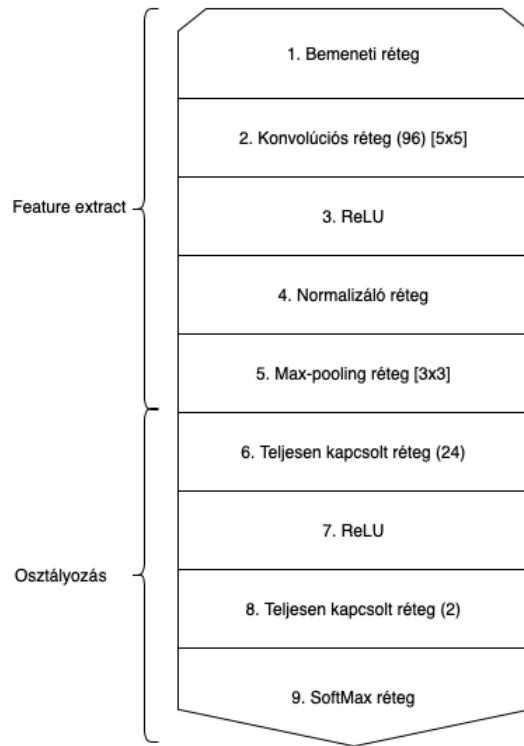
A Deep Galaxy V2 architektúrája alapján felépített modellt 9 epoch-on keresztül futtattuk, de ennek a hálózatnak az eredményei eléggé stagnáltak. Végül 67.71%-os pontosságot ért el a tesztadatokon. A 4.3 ábra felső részén láthatjuk a loss függvényeket, míg az alsó részén az accuracy értékeit az epoch-okon keresztül.

4.2. Saját módosítások

4.2.1. Az architektúrák

Az architekturához hozzáadtunk még két konvolúciós blokkot, annak érdekében, hogy a tulajdonságokat jobban nyerjék ki a hálózatok. Egy konvolúciós blokkot egy konvolúciós rétegből, egy MaxPool rétegből, egy aktivációs rétegből (ReLU) és egy DropOut rétegből állítottunk

4. FEJEZET: KIPRÓBÁLT ARCHITEKTÚRÁK



4.1. ábra. A Deep Galaxy V2 architektúrája

össze (lásd 2.2 fejezet). Az így összeállított feature extraction rész után először csak egy 32 neuronnal rendelkező teljesen kapcsolt réteget adtunk, majd adtunk még ezen réteg előtt egy másik teljesen kapcsolt réteget 96 neuronnal, annak érdekében hogy az osztályozó részét fejlesszük a hálózatnak. Ezen architektúrák a 4.2-es ábrán láthatóak.

4.2.2. Eredmények

Az első módosított architektúrát 10 epoch-on keresztül futtattuk, de a training accuracy 5 epoch után elkezdett stagnálni 0.83 körül és a training loss 0.41 körül (Lásd a 4.4-es ábrán). Ezután módosítottuk megint és 15 epoch-on keresztül futtattuk, de a stagnálás itt is megjelent, ugyancsak 5 epoch után (lásd a 4.5 ábrát).

A tesztadatokat végül 85.38%-os pontossággal prediktálta jól.

4.3. ResNet-18

4.3.1. Az architektúra

Mivel a több rétegű hálózat nem teljesített jelentősen jobban, implementáltunk egy Residual Network¹-ot (a továbbiakban ResNet) is. A residual blokkok két konvolúciós réteget tartalmaznak, lásd 4.6 ábra. A hálózat nyolc blokkot tartalmaz, melyeket megelőz egy konvolúciós réteg, egy normalizációs réteg és egy Max-pooling réteg. A teljes hálózat a 4.7 ábrán látható.

4.3.2. Eredmények

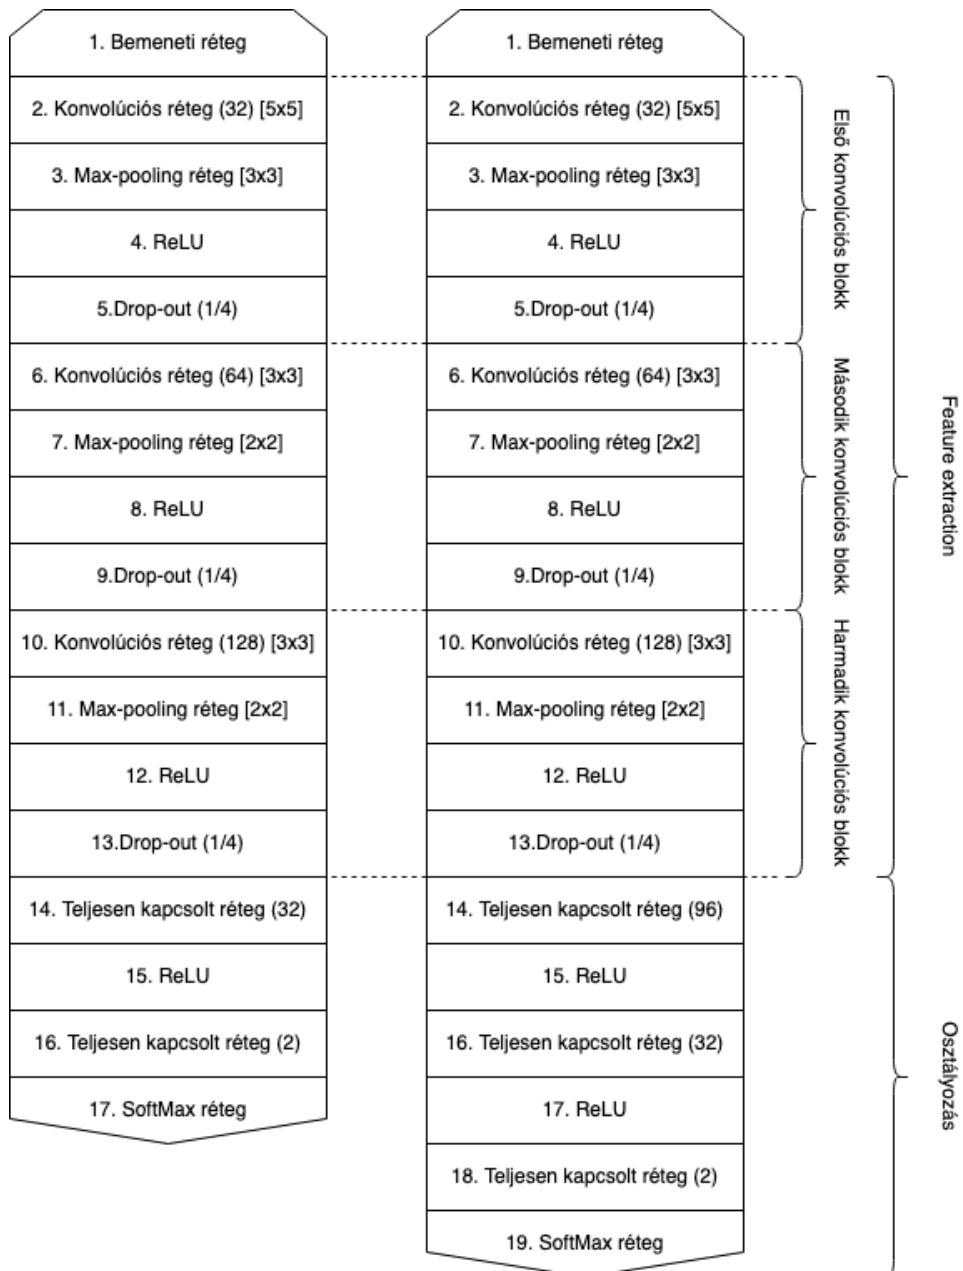
A ResNet-18 már jóval jobban teljesített az előző architektúrákhoz képest, 15 epoch után megközelítette a 0.89-es pontosságot (tanításnál 0.8887, validálásnál 0.8882 volt a pontossága), míg a loss függvény értéke 0.28 körül volt (tanításnál 0.2790, validálásnál 0.2811). A tesztadatokat 88.72%-os pontossággal prediktálta helyesen. A teljes grafikont lásd a 4.8-as ábrán.

4.4. Összehasonlítás

A 4.9-es ábrán láthatjuk a modellek pontosságának összehasonlítását. Jól látható, hogy a ResNet teljesített a legjobban. Továbbá a 4.10-es ábrán láthatjuk a modellek igazságátrixait.

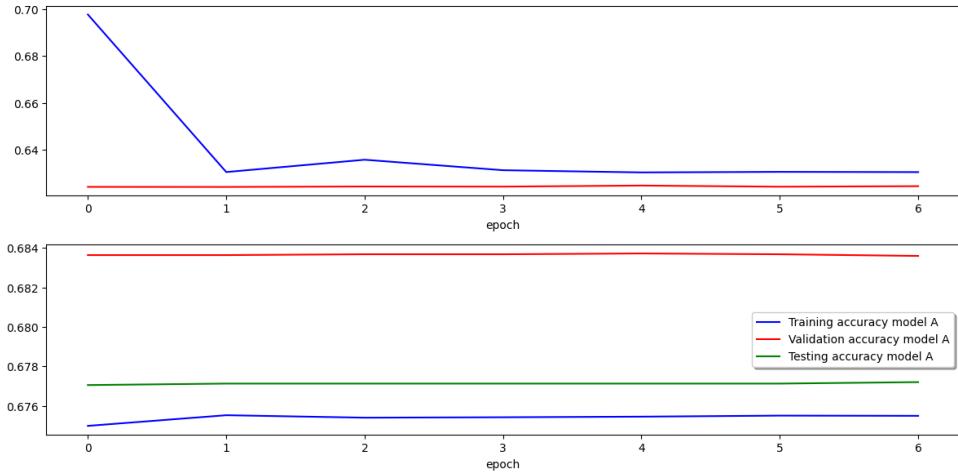
¹<https://www.kaggle.com/code/songrise/implementing-resnet-18-using-keras>

4. FEJEZET: KIPRÓBÁLT ARCHITEKTÚRÁK

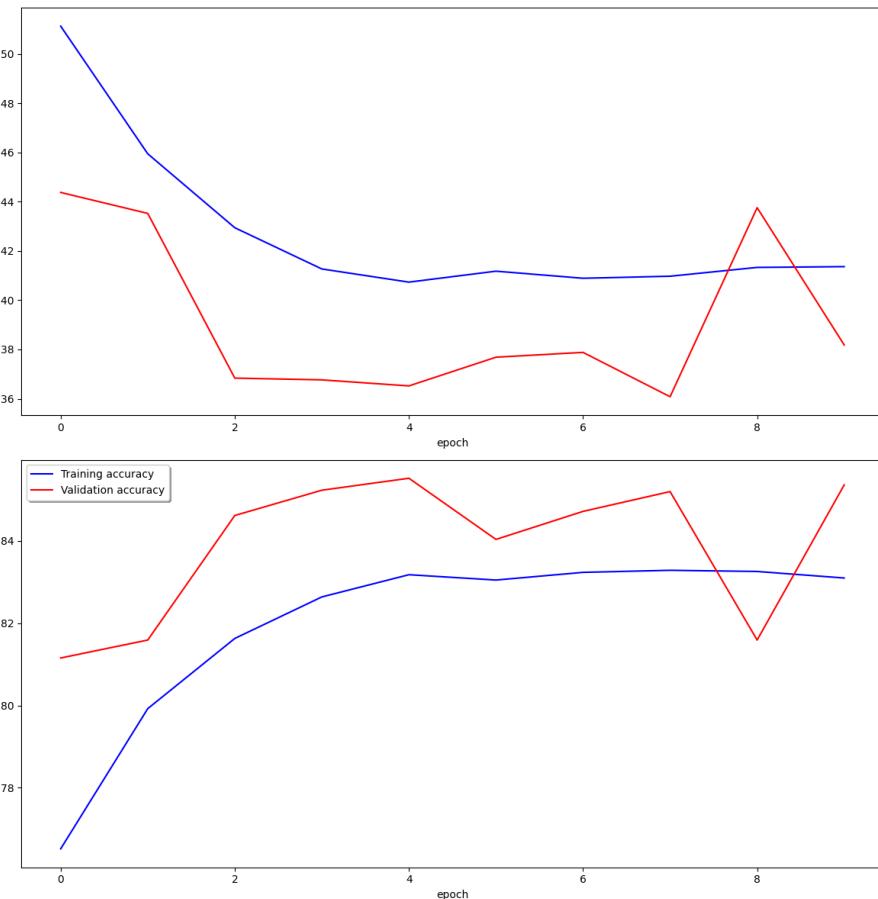


4.2. ábra. Az ábrán a módosított architektúrákat láthatjuk: a bal oldalsó az először módosított, a jobb oldalsó a másodjára módosított szerkezet van feltüntetve.

4. FEJEZET: KIPRÓBÁLT ARCHITEKTÚRÁK

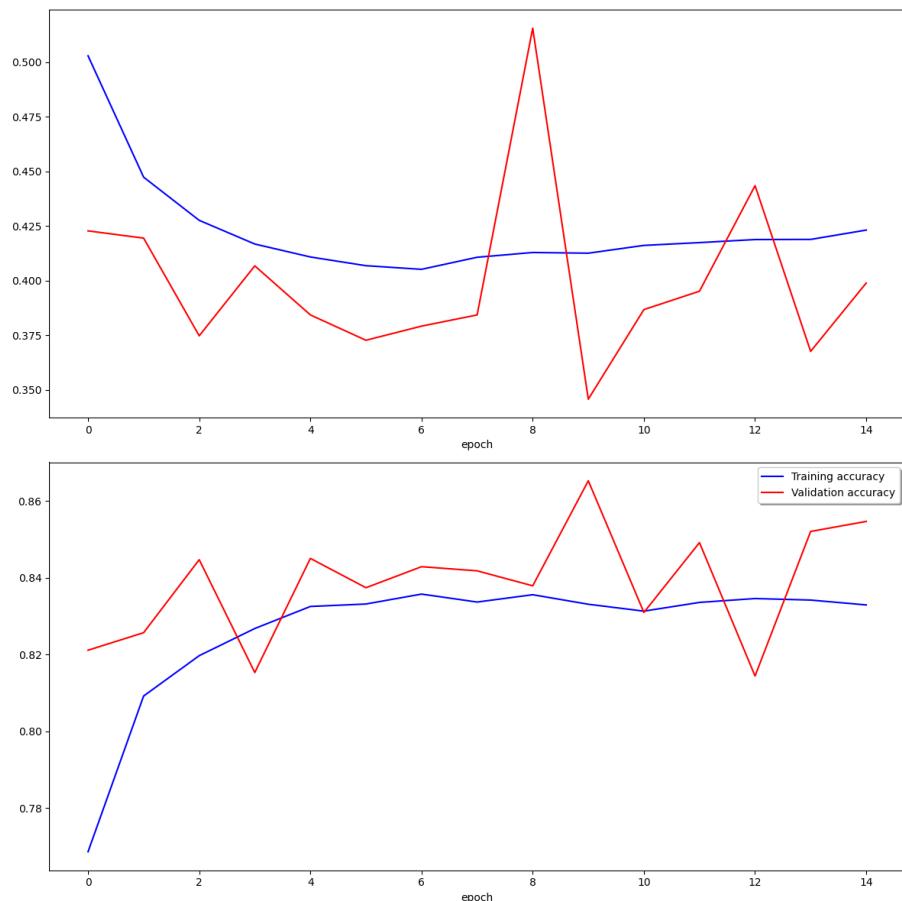


4.3. ábra. Az ábra a Deep Galaxy V2 architektúra eredményeit mutatja. Felső részén láthatjuk kék színnel a training loss függvényt, pirossal a validation loss függvényt, az alsó részén meg kék színnel a training accuracy-t, pirossal pedig a validation accuracy-t és zölddel a testing accuracy-t.



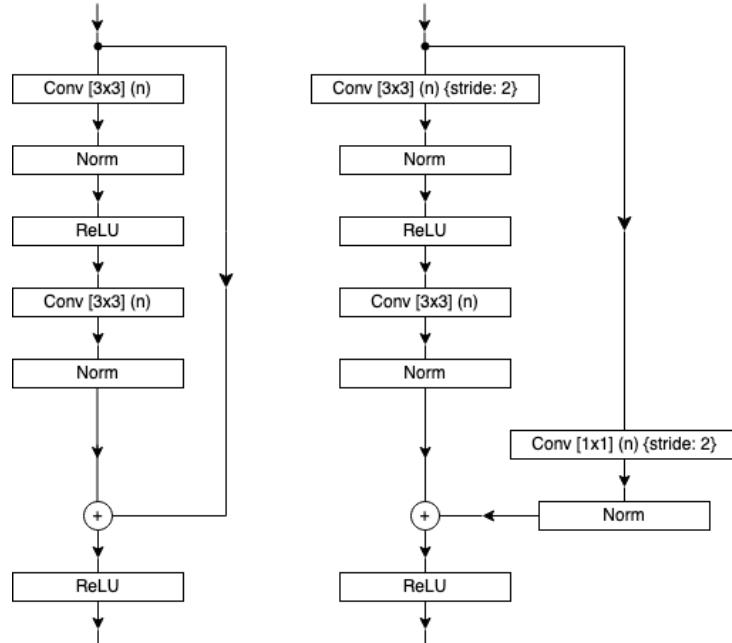
4.4. ábra. Az először módosított architektúra eredményei. A felső ábrán láthatjuk kék színnel a training loss függvényt, pirossal a validation loss függvényt, az alsó ábrán pedig kék színnel a training accuracy-t, pirossal pedig a validation accuracy-t.

4. FEJEZET: KIPRÓBÁLT ARCHITEKTÚRÁK

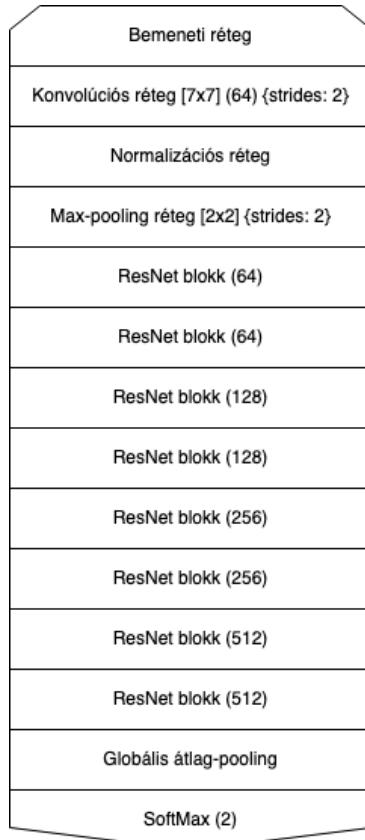


4.5. ábra. A másodjára módosított architektúra eredményei. A felső ábrán láthatjuk kék színnel a training loss függvényt, pirossal a validation loss függvényt, az alsó ábrán pedig kék színnel a training accuracy-t, pirossal pedig a validation accuracy-t.

4. FEJEZET: KIPRÓBÁLT ARCHITEKTÚRÁK

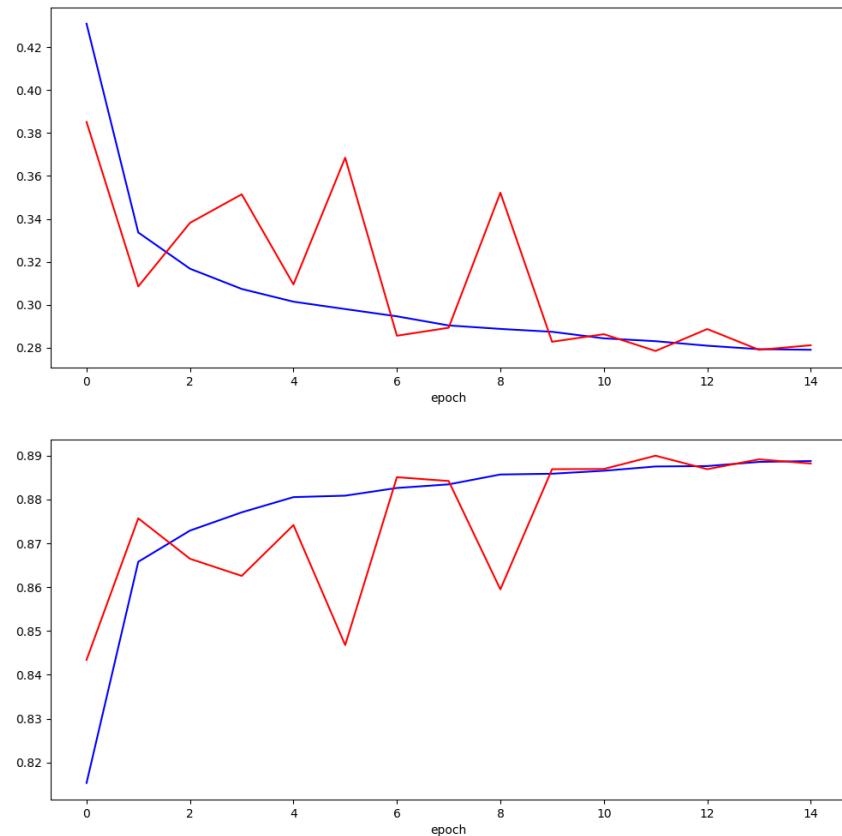


4.6. ábra. Az ábrán a Residual blokkokat láthatjuk. A bal oldali ábrán a tensor dimenziói nem változnak, míg a jobb oldalon igen; ezért a shortcut dimenzióját a blokk kimenetének dimenziójához kell igazítani.

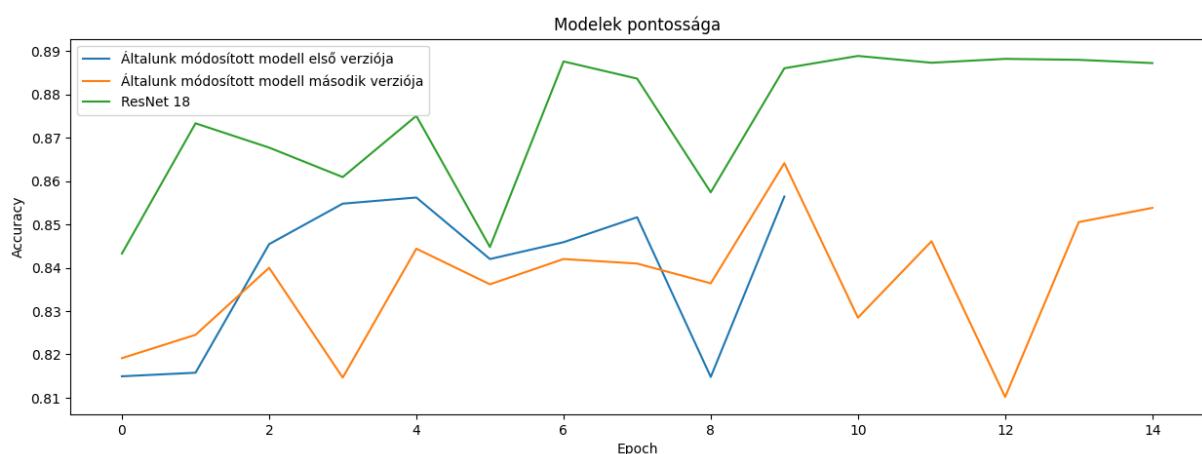


4.7. ábra. Az általunk alkalmazott Residual Network architektúrája.

4. FEJEZET: KIPRÓBÁLT ARCHITEKTÚRÁK

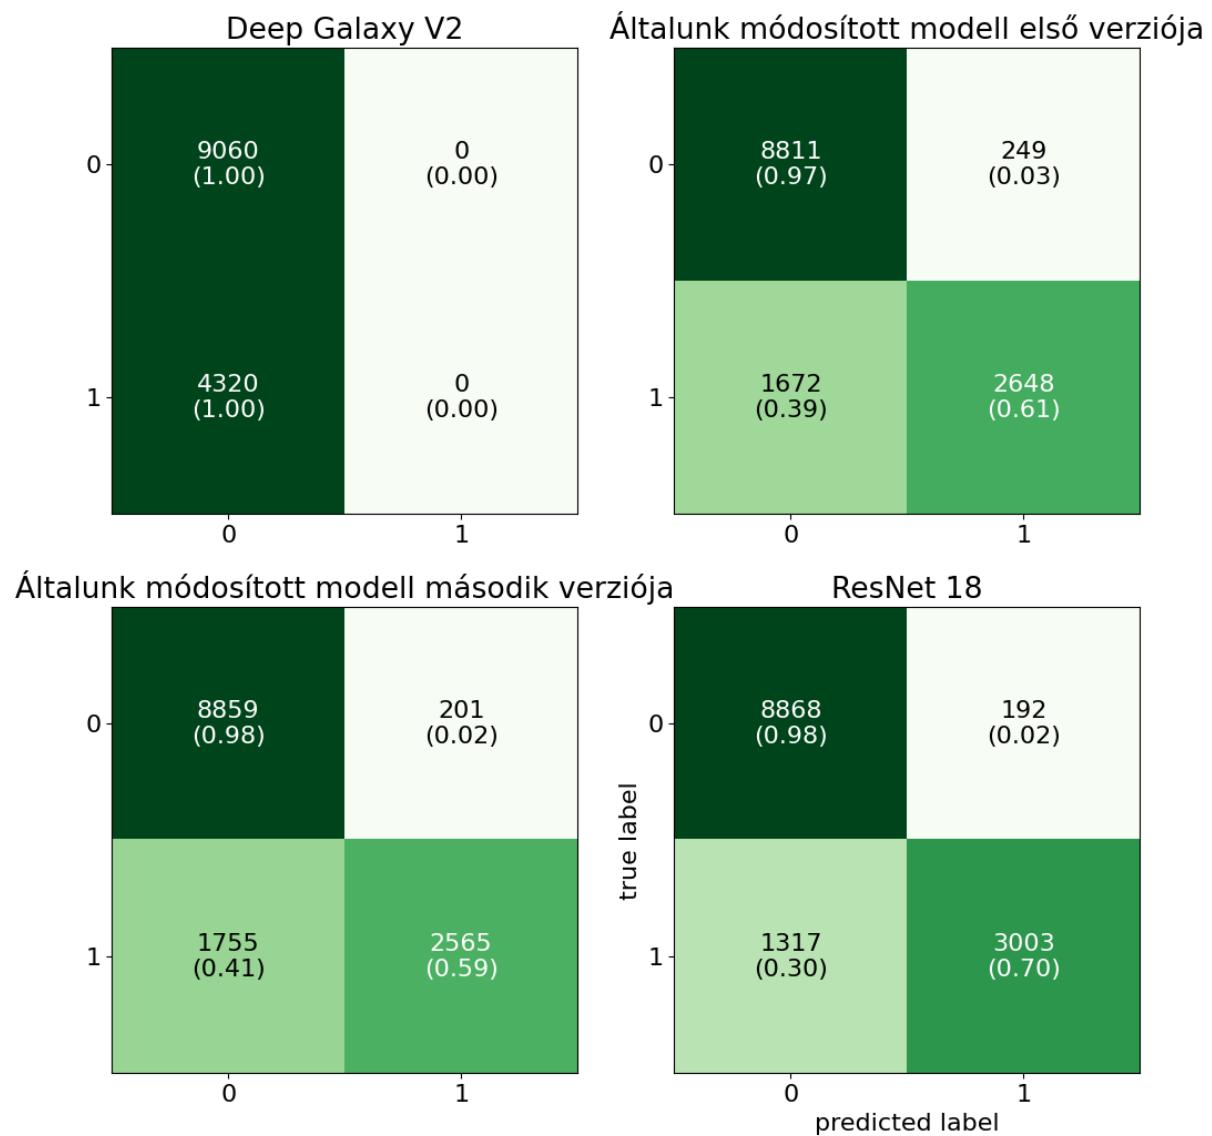


4.8. ábra. A ResNet-18 eredményei. A felső ábrán láthatjuk kék színnel a training loss függvényt, pirossal a validateion loss függvényt, az alsó ábrán pedig kék színnel a training accuracy-t, pirossal pedig a validation accuracy-t.



4.9. ábra. A modellek pontosságának összehasonlítása. Amint látható, a ResNet 18 túltejesíti mindkét módosított modellt.

4. FEJEZET: KIPRÓBÁLT ARCHITEKTÚRÁK



4.10. ábra. A modellek igazságmátrixai.

5. fejezet

JWST Eredmények

A betanított 4 modellt a JWST által szolgáltatott adatokon manuálisan teszteltük. Ezen galaxisok nincsenek még hivatalosan felcímkézve, így a JWST adatait egyfajta koncepció validálásként mutatjuk be. A JWST képek és a hozzájuk tartozó, hálók által prediktált címkék rendre a 5.1 - 5.4 ábrákon tekinthetők meg.

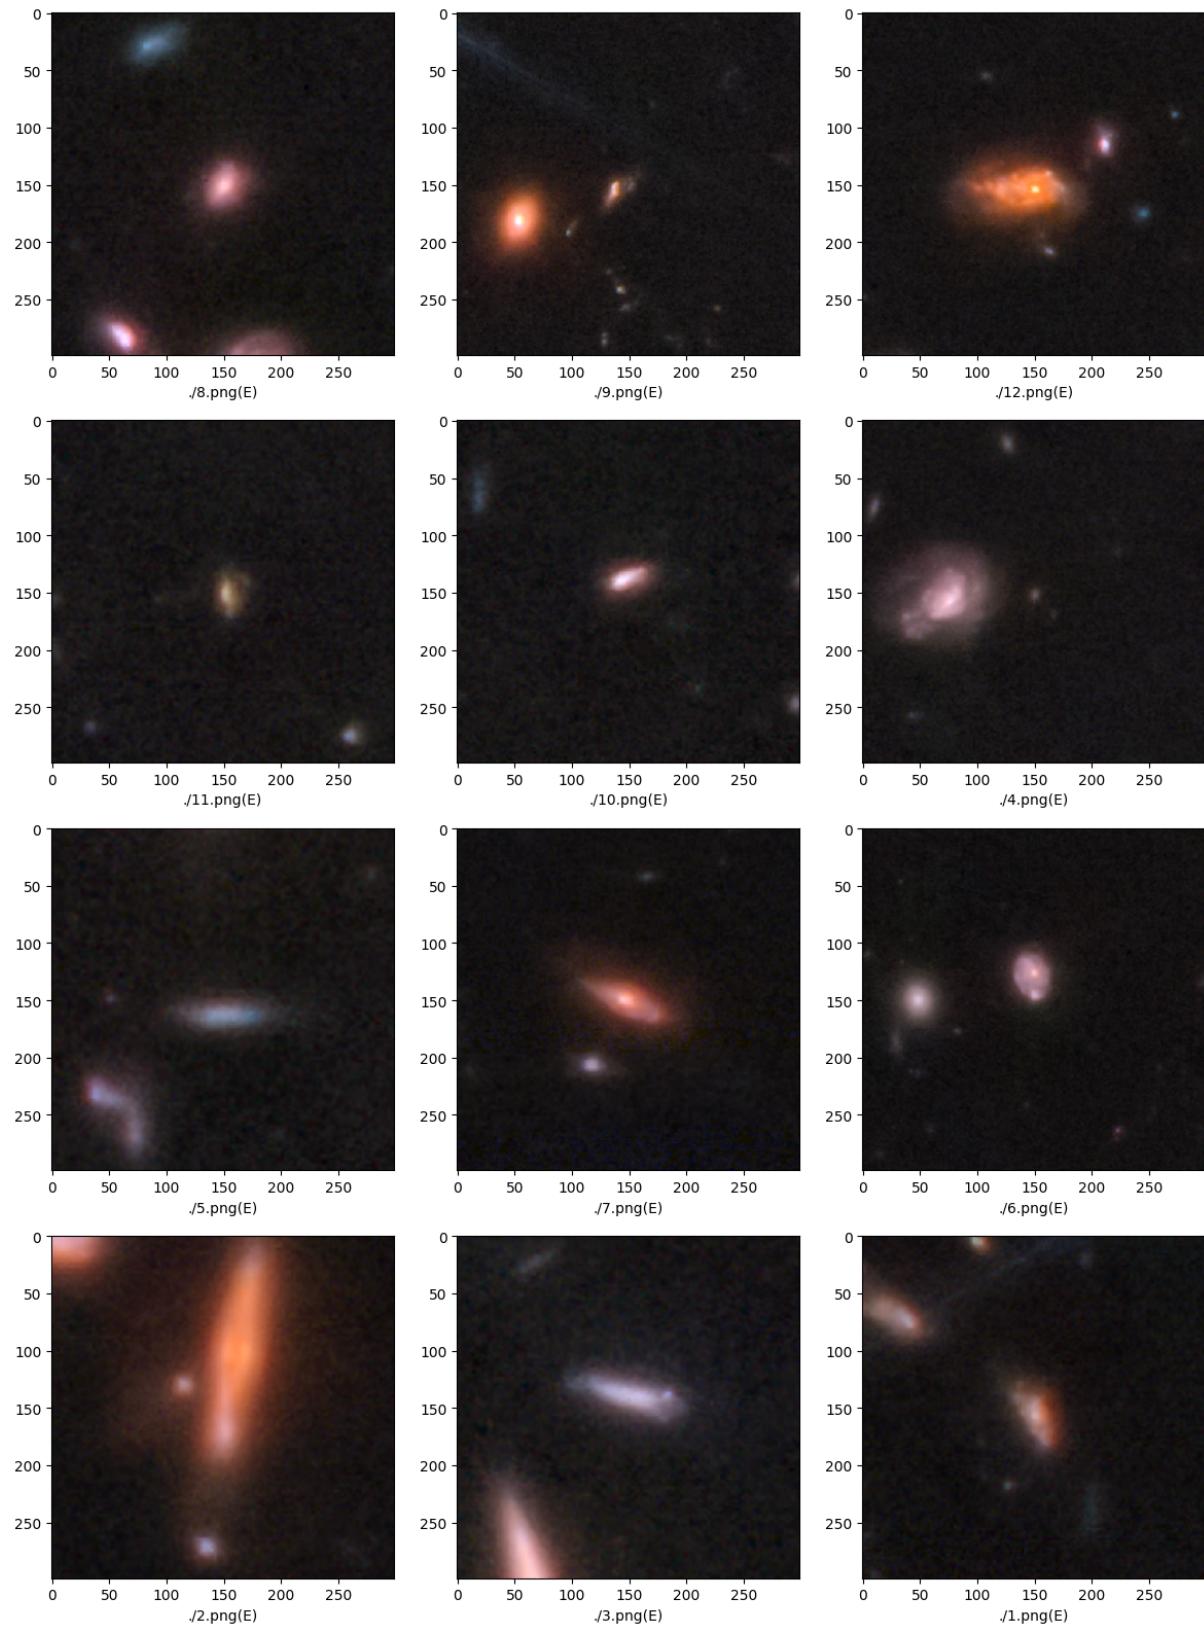
A Deep Galaxy V2 teljes mértékben elliptikus galaxisokat prediktált, míg bizonyos képeken szemmel láthatóan kivehetőek a spirális jellemvonások (mint például a 12-es képen).

Az általunk módosított modellek már több spirális galaxist fedeztek fel. Bár az először módosított modell csak a 12-es képen ismert fel spirális galaxist, a másodjára módosított modell a 6-os és a 3-as képet is spirális galaxisnak címkézte. A hatos képen minden bizonnyal megjelennek a spirális jellemvonások, a 3-ason már vitatható.

Továbbá a ResNet 18 meglepően több spirális galaxist jelzett, mint elliptikusat. Bizonyos képek esetében valóban fellehetjük a spirális galaxisokat (például a 4-esen, 11-esen, talán a 7-esen), ugyanakkor itt már megjelennek megkérőjelezhető jelöltek is, mint a 3-as vagy a 6-os (Bár a 6-on két égitest is megjelenik és az egyik egy spirális és a másik egy elliptikus galaxisra emlékeztethet.). Mindenesetre úgy tűnhet, hogy részletesebben megvizsgálta a ResNet 18 a képeket; illetve a NASA állítását figyelembe véve, miszerint kevesebb elliptikus galaxis van, mint spirális¹, a ResNet eredményei érdekesek lehetnek és több vizsgálatot érdemelnének.

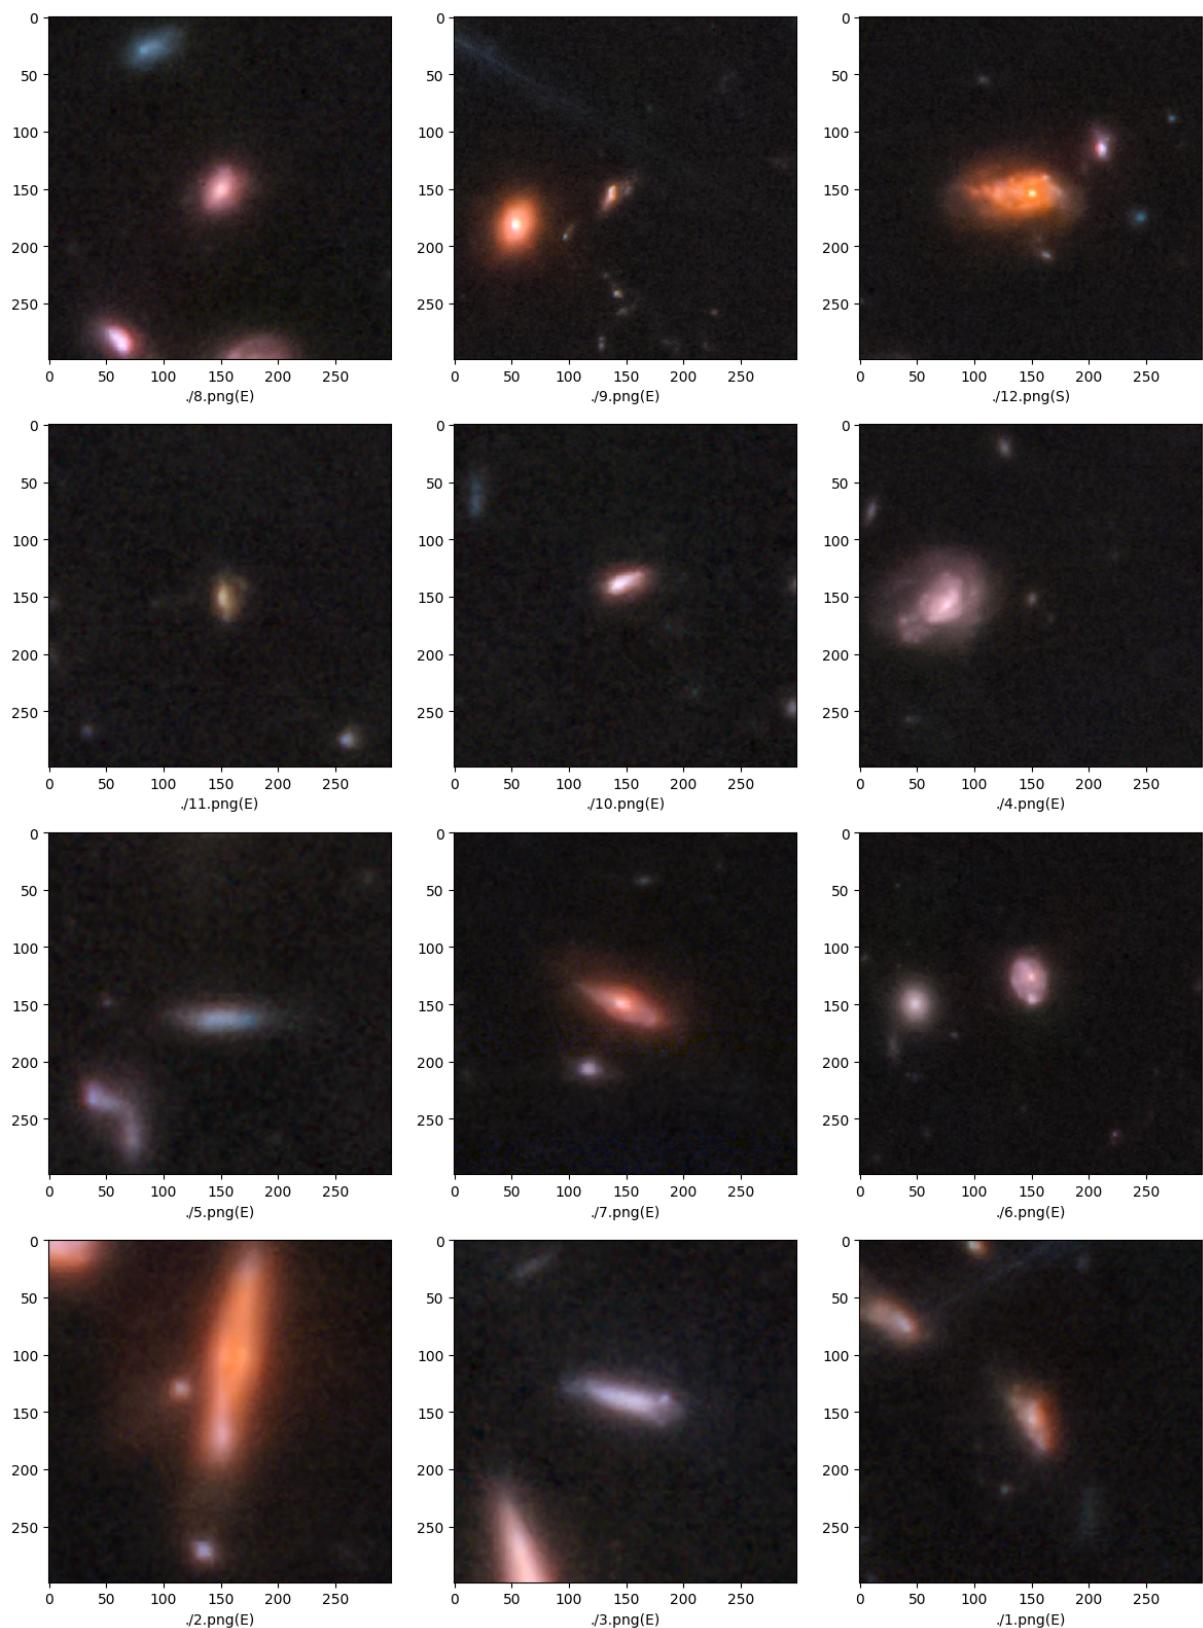
¹<https://universe.nasa.gov/galaxies/types/>-ben az Elliptikus galaxisoknál

5. FEJEZET: JWST EREDMÉNYEK



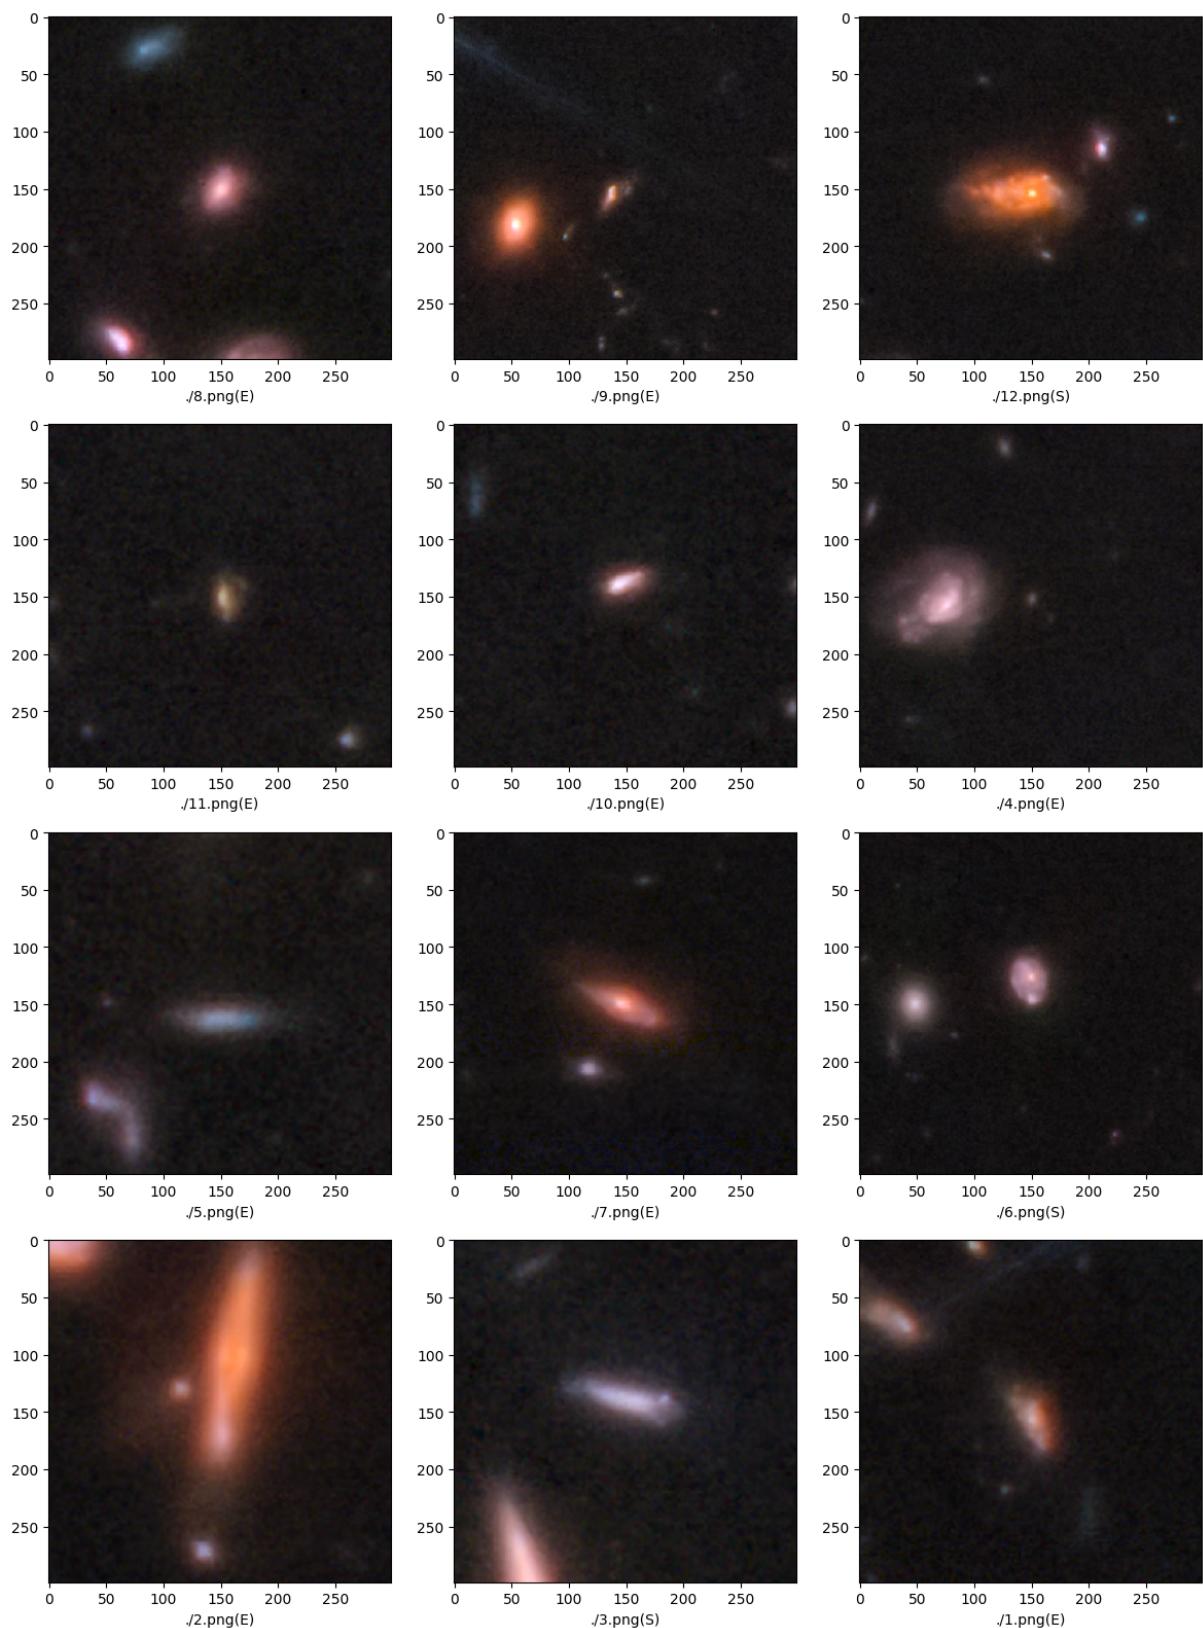
5.1. ábra. Az ábrán a JWST képeken végzett predikciója látható a Deep Galaxy V2-nek.

5. FEJEZET: JWST EREDMÉNYEK



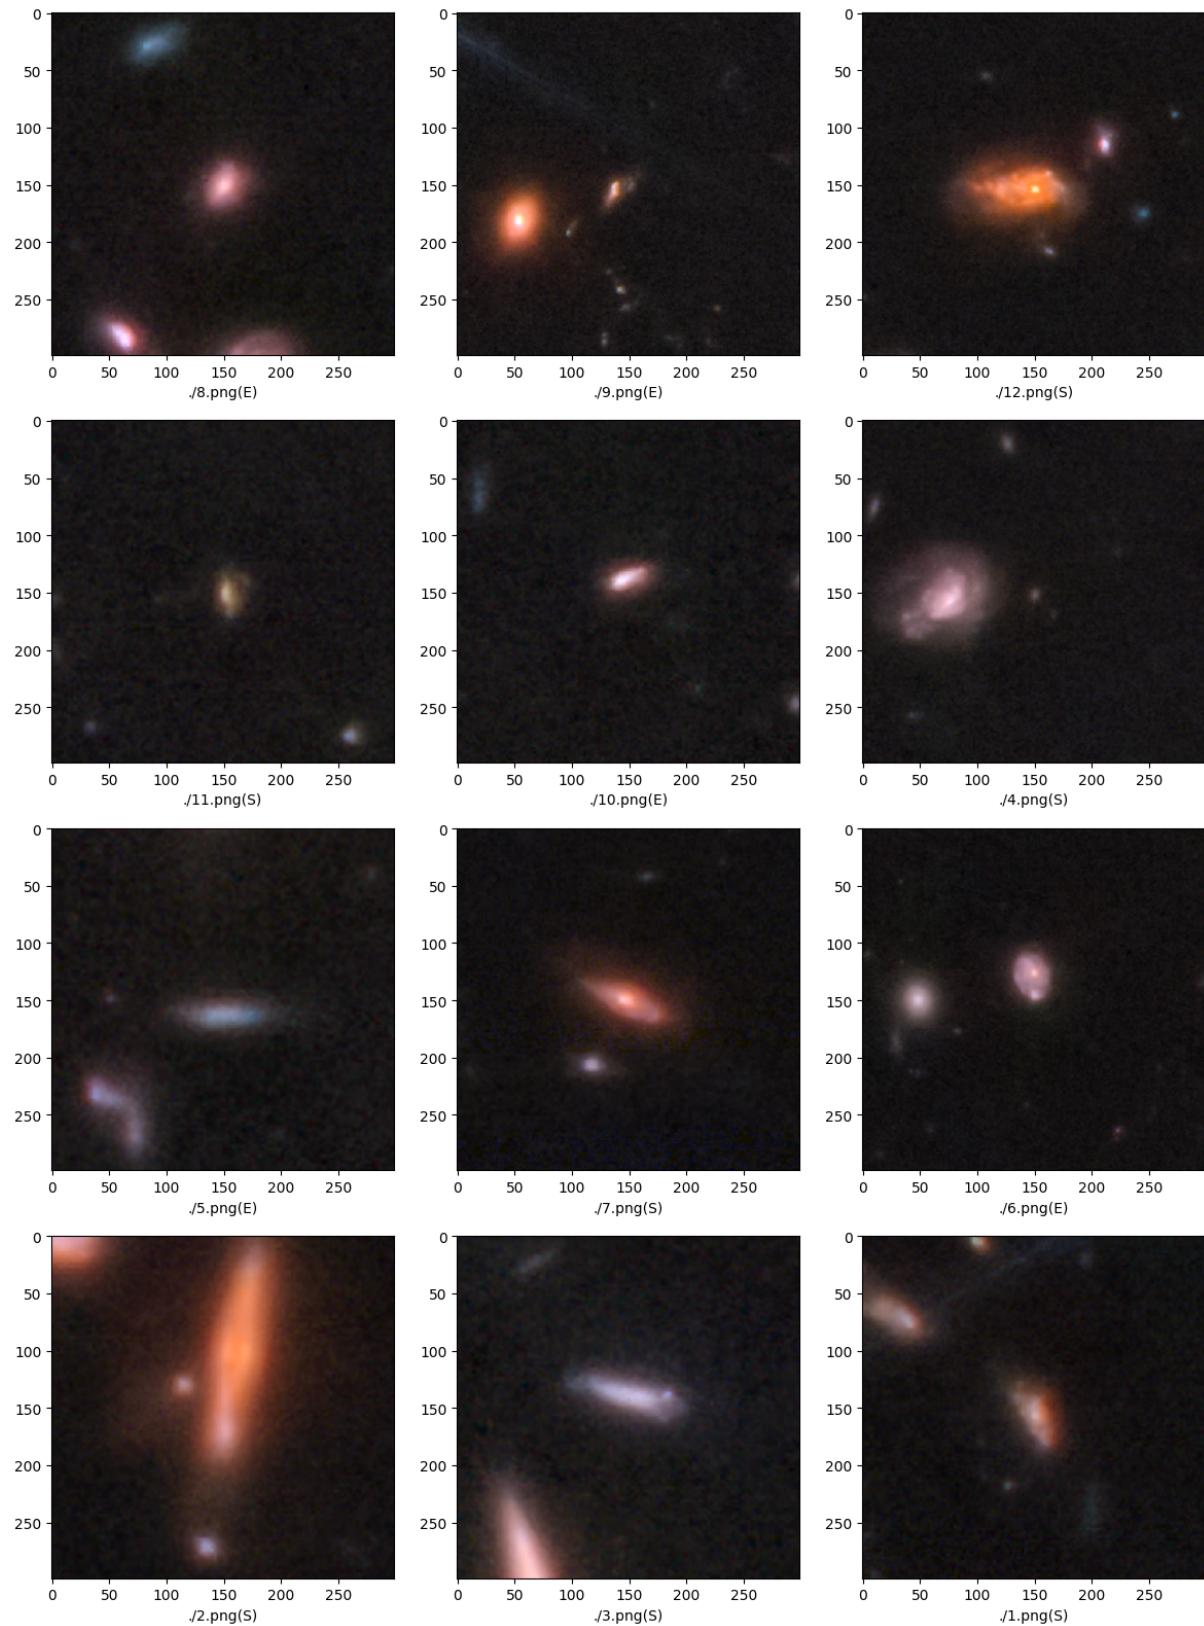
5.2. ábra. Az ábrán a JWST képeken végzett predikciója látható az általunk először módosított hálózatnak.

5. FEJEZET: JWST EREDMÉNYEK



5.3. ábra. Az ábrán a JWST képeken végzett predikciója látható az általunk másodjára módosított hálózatnak.

5. FEJEZET: JWST EREDMÉNYEK



5.4. ábra. Az ábrán a JWST képeken végzett predikciója látható a ResNet-18-nak.

6. fejezet

Felhasznált technológiák

6.1. Python & Jupyter notebook

Mivel a segédanyagok többsége jupyter notebookok formájában érhető el¹ és nagyon sok felhasználható python könyvtár létezik az ilyen adatok kezelésére (lásd 6.1.1 alfejezet), a python scriptek mellett a jupyter notebookok tűnnek a legmegfelelőbbnek.

6.1.1. Használt függőségek

numpy & pandas – Az adatstruktúrák kezelésére

matplotlib – Az adatok vizuális megjelenítésére

sklearn – A tanítási és validálási adatok elválasztására

keras & tensorflow – A Tensorflow-ra épülő Keras csomagot használtam a neurális háló tanításához, validálásához és teszteléséhez.

6.2. MAST Portál

A MAST Portál segítségével töltöttem le a JWST adatait, rákeresve az "ngc*" kulcsszóra², szűrve a JWST missziót.

6.3. Preview

A macOS Preview programjával vágtam ki a képeket.

¹https://spacetelescope.github.io/hellouniverse/notebooks/hello-universe/Classifying_JWST-HST_galaxy_mergers_with_CNNs/Classifying_JWST-HST_galaxy_mergers_with_CNNs.html

²https://en.wikipedia.org/wiki/New_General_Catalogue

7. fejezet

Konklúzió és továbbfejlesztés

7.1. Konklúzió

Galaxisok automatizált osztályozása meglehetősen nehéz feladat a feature-szegény adatok miatt, így a CNN modellek megfelelő szűrőinek és rétegszámainak megválasztása elengedhetetlen a helyes predikciók eléréséhez.

A dolgozatban 4 különböző CNN architektúrát próbáltunk ki az elliptikus és spirális galaxisok bináris osztályozása érdekében. Ezek közül a [Khalifa et al., 2018] cikkből inspirált Deep Galaxy V2 modell teljesített a leggyengébben a maga 67.71%-os tesztpontosságával. Ezt az eredményt két hasonló architektúra követte 85% körüli pontossággal, melyekbe több, különböző szűrmérettel rendelkező konvolúciós réteget illesztettünk, illetve a túltanulás elkerülése végett 25%-os drop-out-ot alkalmaztunk. A legjobban teljesítő modell a ResNet-18 volt, mely több mint 88%-os tanulási-, illetve tesztpontosságot ért el.

A módosított hálók és a ResNet-18 sikerét mi sem bizonyítja jobban, minthogy a JWST egyes adatain sikeresen ismerték fel a spirálgalaxisok jellemvonásait a Deep Galaxy V2 modellel ellentében, ami kizárolag elliptikus galaxisokat prediktált.

Úgy gondolom, hogy a fenti eredmények azt indokolják, hogy mindenkor előre vihet minket az, ha újabb (címkezett) adatok hiányában régebbi eszközök által begyűjtött adatokhoz for dulunk, és ezeket felhasználva tanítunk neurális hálózatokat az újabb űrtávcsöveink által generált adatok feldolgozásához.

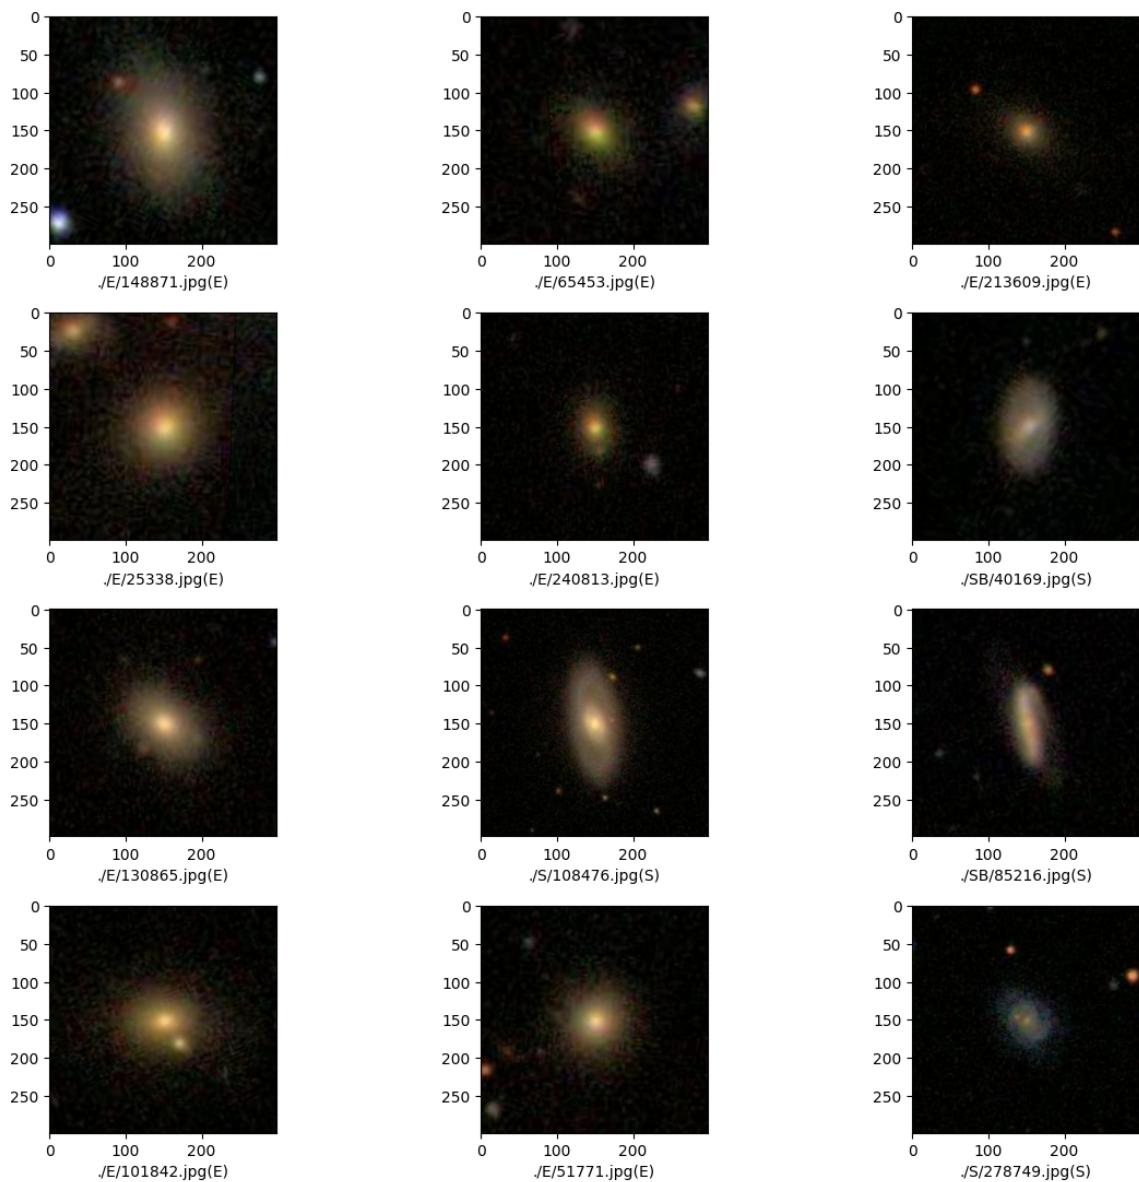
7.2. Továbbfejlesztési lehetőségek

Ahogy a Zooniverse-en belül a GalaxyZoo új képei is osztályozva lesznek és az eredmények publikálva lesznek, mindenkor érdemes lenne a hálózatot ezen új adatokkal letesztelni és egy pontosabb képet kapni a pontosságukról.

A nagyobb tesztállományon kívül mindenkor érdemes lenne más modelleket is kipróbálni és összehasonlítani az eredményeiket, mint a Wide ResNet-et[Zagoruyko és Komodakis, 2016].

A. függelék

Felhasznált adatok példája



A.1. ábra. Tanításhoz felhasznált példaadatok

Irodalomjegyzék

- Abraham, R. G. és Bergh, S.van den. The morphological evolution of galaxies. *Science*, 293(5533):1273–1278, 2001. doi: 10.1126/science.1060855. URL <https://www.science.org/doi/abs/10.1126/science.1060855>.
- Graham, A. W. A galaxy classification grid that better recognizes early-type galaxy morphology. *Monthly Notices of the Royal Astronomical Society*, 487(4):4995–5009, 06 2019. ISSN 0035-8711. doi: 10.1093/mnras/stz1623. URL <https://doi.org/10.1093/mnras/stz1623>.
- He, K., Zhang, X., Ren, S., és Sun, J. Deep residual learning for image recognition. In *Proceedings of the IEEE conference on computer vision and pattern recognition*, pages 770–778, 2016.
- Khalifa, N. E., Hamed Taha, M., Hassanien, A. E., és Selim, I. Deep galaxy v2: Robust deep convolutional neural networks for galaxy morphology classifications. In *2018 International Conference on Computing Sciences and Engineering (ICCSE)*, pages 1–6, 2018. doi: 10.1109/ICCSE1.2018.8374210.
- Lintott, C., Schawinski, K., Bamford, S., Slosar, A., Land, K., Thomas, D., Edmondson, E., Masters, K., Nichol, R. C., Raddick, M. J., Szalay, A., Andreescu, D., Murray, P., és Vandenberg, J. Galaxy Zoo 1: data release of morphological classifications for nearly 900 000 galaxies*. *Monthly Notices of the Royal Astronomical Society*, 410(1):166–178, 12 2010. ISSN 0035-8711. doi: 10.1111/j.1365-2966.2010.17432.x. URL <https://doi.org/10.1111/j.1365-2966.2010.17432.x>.
- Noriega, L. Multilayer perceptron tutorial. *School of Computing. Staffordshire University*, 4 (5):444, 2005.
- Romanowsky, A. J., Douglas, N. G., Arnaboldi, M., Kuijken, K., Merrifield, M. R., Napolitano, N. R., Capaccioli, M., és Freeman, K. C. A dearth of dark matter in ordinary elliptical galaxies. *Science*, 301(5640):1696–1698, 2003. doi: 10.1126/science.1087441. URL <https://www.science.org/doi/abs/10.1126/science.1087441>.
- Willett, K. W., Lintott, C. J., Bamford, S. P., Masters, K. L., Simmons, B. D., Casteels, K. R. V., Edmondson, E. M., Fortson, L. F., Kaviraj, S., Keel, W. C., Melvin, T., Nichol, R. C., Raddick, M. J., Schawinski, K., Simpson, R. J., Skibba, R. A., Smith, A. M., és Thomas, D. Galaxy Zoo 2: detailed morphological classifications for 304 122 galaxies from the Sloan Digital Sky Survey. *Monthly Notices of the Royal Astronomical Society*, 435(4):2835–2860, 09 2013. ISSN 0035-8711. doi: 10.1093/mnras/stt1458. URL <https://doi.org/10.1093/mnras/stt1458>.
- Zagoruyko, S. és Komodakis, N. Wide residual networks. *arXiv preprint arXiv:1605.07146*, 2016.